

Hallucinations des LLM : quand les datasets façonnent la réalité de l'IA

Les modèles de langage, tels que les grands modèles de langage (LLM), jouent un rôle de plus en plus central dans les applications d'intelligence artificielle (IA). Cependant, ces modèles ne sont pas exempts de limitations, parmi lesquelles l'hallucination se révèle être l'une des plus préoccupantes. Par exemple, ChatGPT rencontre des défis significatifs avec les hallucinations, produisant parfois des informations incorrectes tout en ayant l'air cohérentes et plausibles. Mais comment définir "hallucination" en intelligence artificielle ? Si une hallucination se définit techniquement par une erreur mathématique, c'est en fait un concept assez simple : l'hallucination des LLM se produit lorsqu'un modèle génère des informations inexactes ou non fondées, donnant ainsi l'illusion d'une connaissance ou d'une compréhension approfondie là où il n'y en a pas. Ce phénomène met en lumière les défis complexes associés à l'entraînement des modèles, mais également à la constitution de datasets complets et complexes, et par extension à l'annotation des données (c'est-à-dire l'association de métadonnées ou tags à des données non structurées) - données utilisées pour l'entraînement des modèles.

Les chercheurs travaillent activement pour comprendre et atténuer ces hallucinations (et surtout limiter leur impact dans les applications réelles de l'intelligence artificielle), adoptant diverses approches pour améliorer les modèles et réduire les biais.

En façonnant les données utilisées pour l'apprentissage, les datasets et l'annotation influencent directement la précision et la fiabilité des résultats produits par les LLM. Dans cet article, nous partageons un point de vue sur ce sujet !

Quelles sont les causes possibles d'hallucination des LLM ?

Les causes des hallucinations dans les LLM (grands modèles de langage) peuvent être attribuées à plusieurs facteurs principalement liés à des erreurs d'annotation notamment. Elles se manifestent par des réponses incohérentes ou factuellement incorrectes. Ils résultent principalement de la manière dont un modèle est entraîné et de ses limitations intrinsèques. Plusieurs études explorent les causes des hallucinations des LLM, montrant que ces phénomènes sont inévitables pour tout LLM calculable. Nous retenons ici quelques-unes de ces causes :

Données d'entraînement insuffisantes ou biaisées

Les LLM sont entraînés sur de vastes ensembles de données textuelles provenant d'Internet et d'autres sources. Si ces données d'entraînement contiennent des informations incorrectes, biaisées ou incohérentes, le modèle peut apprendre et reproduire ces erreurs, conduisant à des hallucinations.

- **Généralisation excessive**

Les LLM ont tendance à généraliser les informations à partir des données d'entraînement. Parfois, cette généralisation peut aller trop loin, entraînant la génération de contenu plausible mais incorrect. Cette extrapolation incorrecte est une forme d'hallucination”.

- **Manque de contexte ou de compréhension du monde réel**

Les LLM ne possèdent pas une compréhension intrinsèque du monde réel. Ils ne font que manipuler des séquences de mots basées sur des probabilités statistiques. En l'absence de contexte adéquat, ils peuvent générer des retours qui semblent logiques mais qui sont déconnectés de la réalité.

- **Complexité des questions posées**

Les questions ou les prompts complexes ou ambigus peuvent dépasser la capacité du modèle à fournir des réponses correctes. Le modèle peut alors combler les lacunes avec des informations inventées, résultant en des hallucinations.

- **Limites de la capacité de mémoire du modèle**

Les LLM ont des limites quant à la quantité d'information qu'ils peuvent traiter et retenir en même temps. Lorsqu'ils doivent gérer des informations complexes ou de longue haleine, ils peuvent perdre des détails essentiels, menant à des répliques incohérentes ou incorrectes (mais avec toute la confiance du monde).

- **Problèmes d'alignement**

Les LLM ne sont pas toujours parfaitement alignés avec les intentions de leurs utilisateurs ou les objectifs pour lesquels ils sont déployés. Cette déconnexion peut provoquer des réponses inappropriées ou incorrectes.

- **Influence de modèle préexistant**

Les LLM peuvent être influencés par un (ou plusieurs) modèle linguistique préexistant et les structures de phrases communes dans les données d'entraînement. Cela peut entraîner des biais systématiques dans les réponses, y compris des hallucinations.

💡 **Comprendre ces causes est essentiel pour améliorer la fiabilité et la précision des LLM, ainsi que pour développer des techniques pour atténuer les risques d'hallucinations.**

Comment les datasets et l'annotation de données influencent-t-ils les performances des modèles de langage naturel ?

Les LLM reposent sur des ensembles de données massifs pour apprendre à générer du texte de manière cohérente et pertinente. Cependant, la qualité, la précision et la pertinence de ces annotations déterminent directement la performance du modèle. Voici ci-dessous les deux

principaux aspects d'un produit d'intelligence artificielle influencés par les datasets utilisés pour l'entraînement des modèles :

Cohérence des réponses

Lorsque les données sont annotées de manière rigoureuse, le modèle peut établir des liens plus précis entre les entrées et les sorties, ce qui améliore sa capacité à générer des réponses cohérentes et exactes.

À l'inverse, des erreurs ou des incohérences dans l'annotation peuvent introduire des biais, des ambiguïtés ou des informations incorrectes, ce qui peut amener le modèle à produire des résultats erronés, voire à "halluciner" des informations qui ne sont pas présentes dans les données d'entraînement.

Capacité de généralisation

L'influence de l'annotation de données se manifeste également dans la capacité du modèle à généraliser à partir des exemples qu'il a vus pendant l'entraînement. Une annotation de haute qualité aide le modèle à comprendre les nuances du langage, tandis qu'une annotation médiocre peut limiter cette capacité, conduisant à des performances dégradées, particulièrement dans des contextes où la précision est déterminante.

Quels sont les impacts des hallucinations des LLM sur les applications réelles de l' Intelligence Artificielle ?

Les hallucinations des LLM peuvent gravement compromettre la fiabilité des applications d'IA dans lesquelles ces modèles sont intégrés. Lorsque les LLM génèrent des informations incorrectes ou non fondées, cela peut entraîner des erreurs graves dans les décisions automatisées ou assistées par l'IA.

Ceci est particulièrement vrai dans des domaines sensibles tels que la santé, la finance ou le droit. Une perte de fiabilité peut réduire la confiance des utilisateurs dans ces technologies, limitant ainsi leur adoption et leur utilité.

Conséquences dans le domaine de la santé

Dans le domaine médical, par exemple, les hallucinations des LLM peuvent conduire à des diagnostics erronés ou à des recommandations de traitement inappropriées.

Si un modèle LLM génère une information médicale qui semble plausible mais qui est incorrecte, cela pourrait avoir des conséquences graves sur la santé des patients, voire mettre leur vie en danger. L'adoption de ces technologies dans le secteur de la santé dépend donc fortement de la capacité à minimiser ces risques.

Risques dans le secteur financier

Dans le secteur financier, les hallucinations des LLM peuvent entraîner des prises de décisions erronées basées sur des informations inexactes. Cela pourrait se traduire par de mauvaises stratégies d'investissement, des évaluations de risque incorrectes, des fuites liées à des problèmes de sécurité des données, ou même des fraudes.

Les institutions financières doivent donc être particulièrement vigilantes quant à l'utilisation des LLM et s'assurer que les données utilisées par ces modèles sont fiables et correctement annotées. C'est la raison pour laquelle cette industrie est particulièrement prolifique d'un point de vue réglementaire !

Problèmes éthiques et juridiques

Les hallucinations des LLMs soulèvent également des questions éthiques et juridiques. Par exemple, si un modèle LLM génère des informations diffamatoires ou mensongères, cela peut entraîner des poursuites judiciaires pour diffamation ou pour diffusion de fausses informations. De plus, la capacité des LLM à générer des hallucinations pose des défis en termes de transparence et de responsabilité, en particulier dans des contextes où les décisions automatisées peuvent avoir un impact direct sur les individus.

Impacts sur l'expérience utilisateur

Les hallucinations peuvent également dégrader l'expérience utilisateur dans des applications plus courantes, comme les assistants virtuels ou les chatbots. Si ces systèmes fournissent des informations incorrectes ou incohérentes, les utilisateurs peuvent rapidement perdre confiance et cesser d'utiliser ces technologies. De plus, cela peut mener à une frustration accrue chez les utilisateurs, qui peuvent être induits en erreur par des réponses erronées.

Influence sur la réputation des entreprises

Les entreprises qui déploient des applications d'IA basées sur des LLM doivent également être conscientes de tout impact potentiel sur leur réputation. Si un modèle LLM utilisé par une entreprise commence à générer des hallucinations fréquentes, cela peut nuire à l'image de la marque et réduire la confiance des clients.

 **La gestion proactive de ces risques est donc essentielle pour maintenir une réputation positive et pour assurer la pérennité de l'entreprise dans un marché de plus en plus compétitif.**

Comment détecter les hallucinations dans les LLM ?

La détection des hallucinations dans les grands modèles de langage (LLM) est un défi complexe en raison de la nature même des hallucinations, qui impliquent la génération de contenu plausible mais incorrect ou non fondé. Cependant, plusieurs approches peuvent être utilisées pour identifier ces erreurs.

Utilisation de modèles de vérification croisée

Une méthode consiste à utiliser plusieurs modèles LLM pour vérifier les réponses générées. Si différents modèles produisent des réponses divergentes pour une même question ou contexte, cela peut indiquer la présence d'une hallucination. Cette approche repose sur l'idée que les hallucinations sont moins susceptibles d'être cohérentes à travers différents modèles.

Comparaison avec des sources de connaissance fiables

On peut détecter une hallucination des LLMs grâce à la comparaison des réponses des LLM avec des bases de données ou des sources de connaissances fiables et bien établies. Les hallucinations peuvent être détectées lorsque les réponses générées par le modèle contredisent ces sources. Cette méthode est particulièrement utile dans les domaines où des faits précis sont nécessaires, comme la médecine ou le droit.

Analyse des modèles de confiance

Les modèles LLM peuvent également être équipés de mécanismes internes d'évaluation de la confiance pour chaque réponse qu'ils produisent. Les réponses générées avec une faible confiance peuvent être suspectes et nécessiter une vérification plus approfondie. Cela permet de cibler spécifiquement les sorties du modèle qui sont plus susceptibles d'être des hallucinations.

Comment corriger les hallucinations dans les LLM ?

Une fois les hallucinations détectées, plusieurs stratégies peuvent être mises en place pour corriger ou minimiser leur apparition.

Amélioration de l'annotation de données et des datasets

Comme mentionné précédemment, la qualité de l'annotation de données est critique. Améliorer cette qualité, en veillant à ce que les annotations soient précises, cohérentes et exhaustives, peut réduire la probabilité de générer des hallucinations. Des revues régulières des ensembles de données annotées par des experts sont également essentielles.

Fine-tuning du modèle avec des données de correction

Les hallucinations identifiées peuvent être utilisées pour affiner le modèle. En fournissant au LLM des exemples de ses erreurs et des corrections appropriées, le modèle peut apprendre à éviter ces types de dérives à l'avenir. Cette méthode d'apprentissage par la correction est un moyen efficace d'améliorer les performances du modèle.

Incorporation de règles de validation

L'intégration de règles de validation spécifiques, qui vérifient la plausibilité des réponses en fonction du contexte ou des faits connus, peut également limiter les hallucinations. Ces règles peuvent être programmées pour intercepter et réviser les sorties avant qu'elles ne soient présentées à l'utilisateur final.

Conclusion

Les hallucinations des LLM représentent un défi majeur pour la fiabilité et l'efficacité des applications d'intelligence artificielle. En mettant l'accent sur une annotation de données rigoureuse et sur l'amélioration continue des modèles, il est possible de réduire ces erreurs et d'assurer que les LLM fournissent des résultats plus précis et fiables.

Alors que les applications d'IA continuent de se développer, il est extrêmement important de reconnaître et d'atténuer les risques associés aux hallucinations pour garantir des bénéfices durables et responsables aux entreprises de tous secteurs !

Références

<https://www.innovatiana.com/post/llm-hallucination-and-datasets>